Numerical analysis Assignment 1

Q1:

a.

Initial number	Times 2	Rest
0.1	0.2	0
0.2	0.4	0
0.4	0.8	0
0.8	1.6	1
0.6	1.2	1
0.2	0.4	0

So:

$$(0.1)_2 = 0.0\overline{0011}$$

$$(\widetilde{0.1})_{2}^{-} = (0.00011001100110011001100) = 0.1_{10} - 2^{-20} \cdot 0.1_{10} = 0.1_{10} \cdot (1 - 2^{-20})$$

b.
$$\Delta(\widetilde{0.1}) = |\widetilde{0.1} - 0.1| = \left(0.\overbrace{0...0}^{23} \overline{1100}\right)_2 = 2^{-20} \cdot 0.1_{10}$$

$$\delta(\widetilde{0.1}) = \frac{\Delta(\widetilde{0.1})}{0.1} = \left(\frac{0.0...01100}{0.00011}\right)_{2} = \frac{0.0\overline{0011} \cdot 2^{-20}}{0.0\overline{0011} \cdot 2^{0}} = 2^{-20}$$

c.
$$\delta(\widetilde{0.1}) \le 2^{1-d} \to 2^{-20} \le 2^{1-d} \to -20 \le 1 - d \to d \le 21 \to d = 21$$

d.
$$n_1 = 8_h = (8 \cdot 60 \cdot 60 \cdot 10)_{10nth} = (288,000)_{10nth}$$

$$n_2 = 8_h + 2_s = n_1 + (2 \cdot 10)_{10nth} = (288,020)_{10nth}$$

$$\tilde{t}_2 - \tilde{t}_1 = \widetilde{0.1} \cdot n_2 - \widetilde{0.1} \cdot n_1 = \widetilde{0.1} \cdot 20$$

$$t = t_2 - t_1, \ \tilde{t} = \tilde{t}_2 - \tilde{t}_1 \to \Delta \tilde{t} = |t - \tilde{t}| = \left| 0.1 \cdot 20 - \widetilde{0.1} \cdot 20 \right| = \left| 20 \cdot \Delta \left(\widetilde{0.1} \right) \right| = 20 \cdot 2^{-20} \cdot 0.1 = 2^{-19}$$

$$\delta(\tilde{t}) = \frac{\Delta \tilde{t}}{t} = \frac{2^{-19}}{t_2 - t_1} = \frac{2^{-19}}{0.1 \cdot 20} = 2^{-20}$$

- e. Notice that at section d we didn't depend on the absolute number of hours, but on the difference between n2 and n1, which does't changed in this section. So we get the same answer.
- f. $\tilde{t} = \tilde{t}_2 \tilde{t}_1 = 0.1 \cdot n_2 \widetilde{0.1} \cdot n_1 = 0.1 \cdot n_2 0.1_{10} \cdot (1 2^{-20}) \cdot n_1 = 0.1 \cdot (288,020 (1 2^{-20}) \cdot 288,000) = 2.02746582$ $\Delta(\tilde{t}) = |t \tilde{t}| = |2 2.02746582| = 0.02746582$ $\delta(\tilde{t}) = \frac{\Delta(\tilde{t})}{t} = \frac{0.027465}{2} = 0.0137329102$

g.
$$\tilde{t} = \tilde{t}_2 - \tilde{t}_1 = 0.1 \cdot n_2 - \widetilde{0.1} \cdot n_1 = 0.1 \cdot n_2 - 0.1_{10} \cdot (1 - 2^{-20}) \cdot n_1 = 0.1 \cdot (3,600,020 - (1 - 2^{-20}) \cdot 3,6000,000) = 2.343322754$$

$$\Delta(\tilde{t}) = |t - \tilde{t}| = |2 - 2.343322754| = 0.343322754$$

$$\delta(\tilde{t}) = \frac{\Delta(\tilde{t})}{t} = \frac{0.343322754}{2} = 0.171661377$$

Q2 a. 32bit:

1. The smallest positive normalized number with 32bit in IEEE754 is when we have the lowest normalized exponent possible which is 1, and then by subtracting the bias we will get exponent of -126 and the mantissa will be all zeros.

So the number will be:
$$\left(1. \underbrace{0...0}^{23}\right)_2 \cdot 2^{-126} = 2^{-126}$$

2. The smallest positive un-normalized number with 32bit in IEEE754 is when we have the exponent field at 0, which indicates the exponent to be -126 and that the number is un-normalized and starts with 0., and the mantissa will be all zeros and 1 at the last bit.

So the number will be:
$$\left(0. \, \overbrace{0 \, ... \, 0}^{22} \, 1\right)_2 \cdot 2^{-126} = 2^{-149}$$

b.

1. The smallest positive normalized number with <u>64</u>bit in IEEE754 is when we have the lowest normalized exponent possible which is 1, and then by subtracting the bias we will get exponent of -1022 and the mantissa will be all zeros.

So the number will be:
$$\left(1.\overbrace{0...0}^{52}\right)_{2} \cdot 2^{-1022} = 2^{-1022}$$

2. The smallest positive un-normalized number with 64bit in IEEE754 is when we have the exponent field at 0, which indicates the exponent to be -1022 and that the number is un-normalized and starts with 0., and the mantissa will be all zeros and 1 at the last bit.

So the number will be:
$$\left(0.\overline{0...01}\right)_{2} \cdot 2^{-1022} = 2^{-1074}$$

Q3

a.
$$\Delta(\tilde{x}-\tilde{y}) \leq^? \Delta(\tilde{x}) + \Delta(\tilde{y})$$

$$\Delta(\tilde{x}-\tilde{y}) = |(x-y)-(\tilde{x}-\tilde{y})|$$

$$= |(x-\tilde{x})+(\tilde{y}-y)| \stackrel{\subseteq}{\leq} |x-\tilde{x}|+|\tilde{y}-y|$$

$$= |x-\tilde{x}|+|y-\tilde{y}| = \Delta(\tilde{x}) + \Delta(\tilde{y})$$

b.
$$\delta\left(\frac{\tilde{x}^2}{\tilde{y}^2}\right) \lesssim^? 2(\delta \tilde{x} + \delta \tilde{y})$$

We saw in class that for x,y we get $\delta(\tilde{x} \cdot \tilde{y}) \leq \delta(\tilde{x}) + \delta(\tilde{y})$.

We saw in practical session that for x,y we get $\delta\left(\frac{\tilde{x}}{\tilde{y}}\right) \lesssim \delta(\tilde{x}) + \delta(\tilde{y})$

We will use both of those inequalities to prove that $\delta\left(\frac{\tilde{x}^2}{\tilde{y}^2}\right) \lesssim^? 2(\delta \tilde{x} + \delta \tilde{y})$

$$\delta\left(\frac{\tilde{x}^2}{\tilde{y}^2}\right) = \delta\left(\frac{\tilde{x}}{\tilde{y}} \cdot \frac{\tilde{x}}{\tilde{y}}\right) \lesssim \delta\left(\frac{\tilde{x}}{\tilde{y}}\right) + \delta\left(\frac{\tilde{x}}{\tilde{y}}\right) \lesssim \delta(\tilde{x}) + \delta(\tilde{y}) + \delta(\tilde{x}) + \delta(\tilde{y}) = 2(\delta\tilde{x} + \delta\tilde{y})$$

$$Q4 f(x, y) = Z = e^{\alpha(x-y)}$$

$$f_x = \alpha \cdot Z, f_y = -\alpha \cdot Z$$

a.
$$\Delta \tilde{Z} \approx |\nabla f(x, y)| \cdot |(\Delta \tilde{x}, \Delta \tilde{y})| = |\alpha \cdot Z| \cdot \Delta \tilde{x} + |\alpha \cdot Z| \cdot \Delta \tilde{y} = |\alpha \cdot Z| \cdot (\Delta \tilde{x} + \Delta \tilde{y})$$

$$\delta(\tilde{Z}) = \frac{\Delta(\tilde{Z})}{|Z|} = \frac{|\alpha \cdot Z| \cdot \Delta \tilde{x} + |\alpha \cdot Z| \cdot \Delta \tilde{y}}{|Z|} = \frac{|\alpha Z| \cdot (\Delta \tilde{x} + \Delta \tilde{y})}{|Z|} = |\alpha| \cdot (\Delta \tilde{x} + \Delta \tilde{y})$$

b. Let $\Delta X = \Delta Y = 2$:

We want $\delta(\tilde{Z}) \leq 0.05$

From a:

$$\delta(\tilde{Z}) = |\alpha| \cdot (\Delta \tilde{x} + \Delta \tilde{y}) = |\alpha|(2+2) = 4|\alpha| \le 0.05 \rightarrow -0.05 \le 4\alpha \le 0.05$$
$$\rightarrow -0.0125 \le \alpha \le 0.0125$$

היה השיטות זהות לחלוטין מבחינה נומרית. אין יתרון ל"סילוק" החיסור מכיוון שאיבוד משמעות היה כתקיים רק אם $|Z| \sim 0$, מצב שלא יתכן בפונקציית האקספוננט. מבחינת כמות החישובים עדיפה השיטה הראשונה הדורשת פחות הפעלות של פונקציית הexp().

Q5.

a.
$$err 70 = 0.0$$

$$err 7000 = 27.001$$

שגיאת הצובר גדולה יותר ככל שעובר הזמן מכיוון שאנחנו תומכים רק ב-3 ספרות עשרוניות, אז שגיאת הצובר גדולה יותר ככל שעובר הזמן מנסים להוסיף לו אב שיש באקומולטור 1 ואנחנו מנסים להוסיף לו עבור $x \leq 0.00$ עבור $x \leq 0.00$ עבור אזחר החיתוך המנטיסה לא משתנה, ולכן השגיאה גדלה.

72 ההפרשים הנ"ל כל כך שונים זה מזה מכיוון שלאחר 70 איטרציות השגיאה היא 0, ולאחר איטרציות השגיאה היא בערך 10^{-17} , כלומר השגיאה מתחילה להצטבר החל מהצעד ה-72.

בתיאוריה, ההפרש בין err_70 ל- err_70 הוא err_70 ל- err_72 בתיאוריה, ההפרש בין ברך err_8000 ל- err_8000 ל- err_8000 הוא בערך err_8000 כי זה ההפרש האבסולוטי בין המספרים האמיתיים שיחושבו בצעדים ה- err_8000 וה- err_8000

קוד התכנית מצורף בעמוד הבא.